

AI in Marketing Capstone

Concept Note and Implementation Plan

Risk Bazlı Segmentasyon ile Kişiselleştirilmiş Pazarlama Aksiyonu Sistemi

Grup 12

Kişi 1 : İBRAHİM KAYAR
Kişi 2 : ABDULKADİR TEMİZOĞLU
Kişi 3 : ÖZLEM ÇAL
Kişi 4 : TUĞRA CANBAZ

Ağustos 2026

İçindekiler

Project Information **2**

1 Concept Note **2**

1.1 Project Overview 2

1.2 Objectives and Marketing KPIs 2

1.3 Background and Marketing Context 3

1.4 Proposed AI Methodology 4

1.5 Architecture / Workflow Design Diagram 7

1.6 Data Sources 8

1.7 Literature and Industry Review 8

2 Implementation Plan **9**

2.1 Technology Stack 9

2.2 Timeline and Task Distribution 9

2.3 Milestones and Deliverables 10

2.4 Challenges and Mitigation Strategies 11

2.5 Ethical and Responsible AI Considerations 12

2.6 References 13

Project Information

Project Title: Risk Bazlı Segmentasyon ile Kişiselleştirilmiş Pazarlama Aksiyonu Sistemi

1. Concept Note

1.1 Project Overview

Bu proje, e-ticaret platformlarında müşteri kaybı (churn) riskini tahmin ederek bu bilgiyi pazarlama aksiyonlarına dönüştüren yapay zekâ destekli bir sistem geliştirmeyi amaçlamaktadır.

Projenin hedef kitlesi, bir e-ticaret platformunun mevcut müşterileridir. Ele alınan müşteri yolculuğu aşaması ağırlıklı olarak *retention* ve *win-back* süreçleridir. Önerilen sistem, CRM kapsamında e-posta, mobil bildirim veya uygulama içi mesaj gibi dijital kanallarda kullanılabilecek pazarlama aksiyonlarının belirlenmesine destek olacak şekilde tasarlanmıştır.

Temel problem, churn riski birbirinden farklı müşterilerin aynı pazarlama yaklaşımıyla değerlendirilmesidir. Ayrılma ihtimali düşük olan bir müşteri ile kritik risk taşıyan bir müşteriye aynı kampanyayı sunmak hem pazarlama bütçesinin verimsiz kullanılmasına hem de müşteriye gereksiz teklif gönderilmesine neden olabilir.

Bu nedenle ilk olarak her müşteri için churn olasılığı tahmin edilecektir. Daha sonra müşteriler risk seviyelerine göre beş segmente ayrılacaktır. Sistem, bu segmentlere uygulanabilecek farklı pazarlama aksiyonlarını değerlendirecek ve zaman içerisinde daha iyi sonuç veren aksiyonları öğrenmeye çalışacaktır.

Aksiyon seçildikten sonra Generative AI kullanılarak müşterinin özellikleri ve seçilen aksiyonla uyumlu kişiselleştirilmiş bir iletişim metni üretilcektir.

Böylece churn tahmini yalnızca analitik bir skor olarak kalmayacak, pazarlama kararını destekleyen uygulanabilir bir çıktıya dönüştürülecektir.

1.2 Objectives and Marketing KPIs

Projenin ana amacı, churn riski yüksek müşterilerin belirlenmesi ve bu müşterilere uygulanabilecek pazarlama aksiyonlarının daha sistematik bir şekilde seçilmesidir.

Projenin özel hedefleri şunlardır:

- Her müşteri için churn olasılığı tahmin etmek,
- müşterileri churn risklerine göre beş segmente ayırmak,
- farklı segmentler için uygun retention aksiyonlarını değerlendirmek,
- aksiyon seçimini zaman içerisinde öğrenebilen bir yapıya dönüştürmek,
- seçilen aksiyona ve müşteri özelliklerine uygun pazarlama mesajları üretmek,
- aksiyon öncesi ve sonrası risk skorlarını karşılaştırmak.

Teknik Başarı Kriterleri

İlk olarak Logistic Regression modeli baseline olarak kullanılacaktır. Random Forest ve XGBoost modellerinin sonuçları bu baseline ile karşılaştırılacaktır.

Model değerlendirmesinde aşağıdaki metriklerden yararlanılacaktır:

- ROC-AUC,

- Recall,
- Precision,
- F1-score,
- Confusion Matrix,
- Decile Lift.

Veri setindeki churn oranı yaklaşık %16,8 olduğu için yalnızca Accuracy kullanılması yanıltıcı olabilir. Özellikle Recall ve Decile Lift, yüksek riskli müşterilerin ne kadar başarılı şekilde belirlendiğini görmek için kullanılacaktır.

Baseline yaklaşımında Logistic Regression temel alınacak ve daha karmaşık modellerin gerçekten anlamlı bir performans artışı sağlayıp sağlamadığı incelenecektir.

Pazarlama Başarı Kriterleri

Pazarlama tarafında prototip aşğıdaki göstergeler üzerinden değerlendirilecektir:

- Segment bazında ortalama churn riski değışimi,
- Segment 4 ve Segment 5'te elde edilen simüle edilmiş risk azalması,
- aksiyon başına ortalama reward,
- zaman içerisindeki cumulative reward,
- segmentlere göre aksiyon seçim dağılımı,
- üretilen pazarlama mesajının seçilen aksiyon ve müşteri profiliyle uyumu.

Gerçek kampanya sonucu içeren bir veri bulunmadığı için retention rate ve gerçek gelir artışı gibi KPI'lar bu aşamada doğrudan ölçülemeyecektir. Bunlar sistemin gerçek işletme verisiyle uygulanması durumunda takip edilecek KPI'lar olarak değerlendirilecektir.

1.3 Background and Marketing Context

Müşteri churn'ü, özellikle tekrar satın almanın önemli olduğu e-ticaret işletmelerinde önemli bir müşteri ilişkileri yönetimi problemidir. Müşterinin kaybedilmesi yalnızca mevcut satışın kaybedilmesi anlamına gelmez; aynı zamanda işletmenin yeni müşteri kazanmak için yeniden pazarlama maliyetine katlanmasına neden olabilir.

Churn prediction çalışmalarında müşterinin geçmiş davranışları kullanılarak gelecekte ayrılma ihtimali tahmin edilmektedir. Makine öğrenmesi modelleri bu amaçla müşteri davranışlarındaki çok sayıda sinyali aynı anda değerlendirebilir.

Ancak churn tahmini tek başına bir pazarlama aksiyonu değildir. Örneğin bir müşterinin churn olasılığının %80 olarak tahmin edilmesi, bu müşteriye hangi teklifin gönderilmesi gerektiğini doğrudan göstermez.

Aynı şekilde yüksek churn riskine sahip her müşteriye yüksek maliyetli bir indirim vermek de verimli olmayabilir. Bazı müşteriler küçük bir sadakat teklifiyle tekrar etkileşime geçebilirken bazı müşteriler için daha güçlü bir win-back aksiyonu gerekebilir.

Bu proje bu nedenle churn prediction ile pazarlama aksiyonu arasına bir karar katmanı eklemektedir.

Önerilen yaklaşım genel olarak şu yapıdadır:

MteriVerisi → ChurnTahmini → RiskSegmenti → AksiyonSeimi → Kiiselletirilmiletiim

Yapay zekâ projede üç farklı amaçla kullanılmaktadır. Predictive machine learning churn riskini hesaplamakta, Thompson Sampling pazarlama aksiyonlarının seçiminde kullanılmakta ve Generative AI seçilmiş aksiyona uygun iletişim içeriğini oluşturmaktadır.

1.4 Proposed AI Methodology

Önerilen sistem birbiriyle bağlantılı yedi aşamadan oluşmaktadır.

1. Veri Hazırlama

İlk aşamada veri setinin yapısı incelenecek ve modellemeye uygun hale getirilecektir.

Bu aşamada:

- eksik değerler kontrol edilecek,
- tekrar eden kayıtlar incelenecek,
- kategorik değişkenler encode edilecek,
- sayısal değişkenlerin dağılımları kontrol edilecek,
- gerekli durumlarda ölçeklendirme yapılacaktır,
- CustomerID model girdilerinden çıkarılacaktır.

Ayrıca churn sınıfındaki dengesizlik model geliştirme aşamasında dikkate alınacaktır.

2. Churn Prediction

İlk model olarak Logistic Regression kullanılacaktır. Bu model, sonraki modeller için yorumlanabilir bir baseline oluşturacaktır.

Daha sonra Random Forest ve XGBoost modelleri uygulanacaktır.

Her model müşteri için aşağıdaki olasılığı tahmin edecektir:

$$p_i = P(Y_i = 1 | X_i)$$

Burada p_i , müşterinin tahmin edilen churn olasılığıdır.

Modeller ROC-AUC, Recall, F1-score ve Decile Lift gibi metriklerle karşılaştırılacak ve sonraki aşamalarda kullanılacak model bu sonuçlara göre seçilecektir.

3. Risk Bazlı Segmentasyon

Seçilen modelden elde edilen churn olasılıkları büyükten küçüğe sıralanacaktır.

Müşteriler yaklaşık eşit büyüklükte beş gruba ayrılacaktır.

Segment	Risk Seviyesi
1	En düşük risk
2	Düşük risk
3	Orta risk
4	Yüksek risk
5	Kritik risk

Örneğin en yüksek churn olasılığına sahip yaklaşık %20’lik müşteri grubu Segment 5 olarak değerlendirilecektir.

Bu aşamanın amacı, modelin ürettiği sürekli olasılık değerlerini pazarlama ekibinin daha kolay kullanabileceği risk gruplarına dönüştürmektir.

4. Pazarlama Aksiyonlarının Tanımlanması

Prototipte farklı yoğunluk ve maliyet düzeylerini temsil eden pazarlama aksiyonları tanımlanacaktır.

Örnek aksiyonlar:

- herhangi bir aksiyon uygulamama,
- engagement / hatırlatma mesajı,
- sadakat teklifi,
- indirim teklifi,
- win-back teklifi.

“No Action” seçeneğinin de bulunması önemlidir. Çünkü sistemin her müşteriye mutlaka bir kampanya göndermesi amaçlanmamaktadır.

5. Thompson Sampling ile Aksiyon Seçimi

Aksiyonların tamamen sabit kurallarla belirlenmesi yerine Thompson Sampling tabanlı bir Multi-Armed Bandit yaklaşımı kullanılacaktır.

Başlangıçta sistem hangi aksiyonun hangi segmentte daha iyi çalıştığı konusunda sınırlı bilgiye sahip olacaktır. Bu nedenle farklı aksiyonları deneyecektir.

Yeni sonuçlar elde edildikçe daha başarılı sonuç veren aksiyonların seçilme olasılığı artacaktır.

Bu yaklaşımın temel amacı iki durumu dengelemektir:

- **Exploration:** Farklı aksiyonları deneyerek yeni bilgi edinmek,
- **Exploitation:** Daha önce iyi sonuç veren aksiyonları daha sık kullanmak.

Bu sayede aksiyon seçimi statik bir kural listesinden ziyade zaman içerisinde öğrenebilen bir yapıya dönüşecektir.

6. Aksiyon Etkisinin Simülasyonu

Kullanılan veri setinde müşterilere geçmişte hangi retention aksiyonlarının uygulandığı ve müşterilerin bu aksiyonlardan sonra nasıl davrandığı bilgisi bulunmamaktadır.

Bu nedenle gerçek bir A/B testi veya gerçek kampanya etkisi hesaplanamayacaktır.

Prototipte sistemin aksiyon seçme ve öğrenme mekanizmasını göstermek için bir simülasyon ortamı oluş-

turulacaktır.

Her segment–aksiyon kombinasyonu için olası bir etki aralığı tanımlanacaktır. Simülasyon sırasında bu aralıktan bir etki değeri üretilerek müşterinin risk skoru güncellenecektir.

Örneğin:

$$Risk_{sonra} = \max(0, Risk_{nce} - Etki)$$

şeklinde basit bir güncelleme kullanılabilir.

Aksiyon öncesi ve sonrası arasındaki değişim:

$$Reward = Risk_{nce} - Risk_{sonra}$$

şeklinde hesaplanarak bandit algoritmasına geri beslenecektir.

Buradaki önemli nokta, bu değerlerin gerçek kampanya etkisini kanıtlamamasıdır. Simülasyon yalnızca önerilen karar sisteminin nasıl çalışabileceğini göstermek için kullanılacaktır.

Gerçek bir uygulamada bu katmanın A/B testleri, kampanya-response verileri veya uplift modeling gibi yöntemlerle desteklenmesi gerekecektir.

7. Generative AI ile İçerik Üretimi

Pazarlama aksiyonu belirlendikten sonra Generative AI kullanılacaktır.

Bu projede LLM'in görevi pazarlama aksiyonuna karar vermek değildir. Aksiyon Thompson Sampling katmanında belirlenecektir.

LLM'e örneğin aşağıdaki bilgiler verilebilir:

- müşterinin risk segmenti,
- seçilen pazarlama aksiyonu,
- tercih edilen ürün kategorisi,
- tenure,
- geçmiş kupon kullanımı,
- sipariş davranışı.

Bu bilgiler kullanılarak müşteriye gönderilebilecek kısa bir e-posta, push notification veya uygulama içi mesaj üretilenektir.

Örnek prompt yapısı:

Müşterinin risk segmenti, tercih ettiği kategori ve seçilmiş pazarlama aksiyonu aşağıda verilmiştir. Yalnızca verilen bilgileri kullanarak kısa ve doğal bir retention mesajı oluşturun. Verilmeyen bir indirim oranı, ürün, fiyat veya kampanya koşulu oluşturma.


Bu sınırlar özellikle yanlış veya işletme tarafından onaylanmamış kampanya bilgilerinin üretilmesini azaltmak amacıyla kullanılacaktır.

Baseline ve Değerlendirme Yaklaşımı

Sistemin farklı bileşenleri farklı baseline'larla karşılaştırılacaktır.

Bileşen	Baseline	Değerlendirme
Churn Prediction	Logistic Regression	Random Forest ve XGBoost ile ROC-AUC, Recall, F1 ve Lift karşılaştırması
Aksiyon Seçimi	Sabit / rastgele aksiyon seçimi	Thompson Sampling ile average ve cumulative reward karşılaştırması
İçerik Üretimi	Genel kampanya mesajı	Kişiselleştirilmiş mesajın müşteri ve aksiyonla uyumu

1.5 Architecture / Workflow Design Diagram



Şekil 1: Önerilen sistemin yüksek seviyeli çalışma akışı

Veri hazırlama aşaması ham müşteri verisini modellemeye hazır hale getirmektedir. Churn prediction modeli her müşteri için bir risk olasılığı üretmektedir. Bu olasılıklar risk segmentlerine dönüştürülmektedir.

Thompson Sampling katmanı uygulanacak pazarlama aksiyonunu seçmektedir. Generative AI ise bu aksiyona uygun müşteri iletişimini oluşturmaktadır.

Gerçek kampanya-response verisi bulunmadığından müşteri tepkisi prototipte simüle edilmektedir. Son aşamada teknik ve pazarlama metrikleri değerlendirilmekte ve sonuçlar insan kontrolüne sunulmaktadır.

1.6 Data Sources

Projede Kaggle üzerinde yayımlanan *Ecommerce Customer Churn Analysis and Prediction* veri seti kullanılacaktır. Veri CSV formatındadır ve müşteri seviyesinde 5.630 kayıt ile 20 değişken içermektedir. Veri setindeki churn oranı yaklaşık %16,8'dir.

Hedef değişken *Churn*'dür. Veri setinde ayrıca *Tenure*, *PreferredLoginDevice*, *CityTier*, *WarehouseToHome*, *PreferredPaymentMode*, *HourSpendOnApp*, *PreferredOrderCat*, *SatisfactionScore*, *Complain*, *CouponUsed*, *OrderCount*, *DaySinceLastOrder* ve *CashbackAmount* gibi müşteri davranışını ve müşteri-platform ilişkisini temsil eden değişkenler bulunmaktadır.

Veri hazırlama aşamasında eksik değerler, duplicate kayıtlar, değişken tipleri ve sınıf dağılımı kontrol edilecektir. Kategorik değişkenler uygun şekilde encode edilecek ve CustomerID tahmin modeline dahil edilmeyecektir.

Veri seti kamuya açık bir eğitim/araştırma veri setidir ve doğrudan müşteriyle iletişim kurulabilecek kişisel kimlik bilgileri içermemektedir. Gerçek bir işletme uygulamasında ise müşteri verilerinin kullanımı için KVKK, veri minimizasyonu, erişim kontrolü ve gerekli durumlarda kullanıcı rızası dikkate alınmalıdır.

1.7 Literature and Industry Review

Literatürde churn prediction, müşterilerin gelecekte işletmeyi terk etme olasılığını belirlemek amacıyla yaygın olarak kullanılmaktadır. Bununla birlikte yalnızca churn olasılığının tahmin edilmesi, hangi müşterinin hangi pazarlama aksiyonundan gerçekten faydalanacağını göstermemektedir. Devriendt, Berrevoets ve Verbeke (2021), churn yönetiminde geleneksel prediction yaklaşımı ile uplift modeling arasındaki farkı ele alarak kampanyanın müşteride oluşturduğu ek etkinin dikkate alınmasının önemini göstermektedir. Sawant ve arkadaşları (2018) ise contextual multi-armed bandit yaklaşımını causal marketing problemi kapsamında incelemiş ve pazarlama aksiyonlarının adaptif biçimde optimize edilebileceğini göstermiştir. Thompson Sampling de exploration ve exploitation arasında denge kurabilen bir bandit yöntemi olarak bu karar problemiyle uyumludur. Gerçek dünya tarafında contextual bandit yaklaşımlarının e-posta kişiselleştirme ve recommendation problemlerinde kullanıldığı örnekler bulunmaktadır. Bu projenin pratik fırsatı churn prediction, risk segmentasyonu, adaptif aksiyon seçimi ve Generative AI ile içerik üretimini tek bir prototip akışında birleştirmektir. Ancak mevcut veri setinde gerçek treatment ve campaign-response bilgisi bulunmadığından aksiyonların nedensel etkisi ölçülememektedir. Bu nedenle bu aşama simülasyonla gösterilecek ve gerçek bir uygulamada A/B testing veya uplift modeling ile geliştirilmesi önerilecektir.

2. Implementation Plan

2.1 Technology Stack

Projede mümkün olduğunca erişilebilir ve uygulanabilir araçlar kullanılacaktır.

Bileşen	Teknoloji / Araç
Programlama Dili	Python
Notebook / Geliştirme	Jupyter Notebook, Google Colab
Veri İşleme	Pandas, NumPy
Görselleştirme	Matplotlib, Seaborn
Makine Öğrenmesi	Scikit-learn
Boosting Modeli	XGBoost
Bandit Algoritması	Python ile Thompson Sampling implementasyonu
Generative AI	Gemini API
Prototype / Dashboard	Streamlit
Versiyon Kontrolü	Git ve GitHub
Raporlama	LaTeX / Overleaf

Python ve Scikit-learn tabular veri üzerinde churn modeli geliştirmek için yeterli araçları sağlamaktadır. XGBoost, klasik modellere göre daha güçlü bir alternatif olarak karşılaştırmaya dahil edilecektir.


Thompson Sampling'in proje ihtiyaçlarına göre Python içerisinde uygulanması planlanmaktadır. Böylece ek bir platform bağımlılığı oluşturulmayacaktır.

Generative AI aşamasında Gemini API kullanılması planlanmaktadır. Streamlit ise yalnızca sonuçları daha anlaşılır göstermek ve final demo sırasında müşteri bazlı örnek akışı göstermek için kullanılacaktır.

2.2 Timeline and Task Distribution

Projenin kalan uygulama süreci altı haftalık bir plan üzerinden oluşturulmuştur.

Timeline



Şekil 2: Capstone uygulama zaman planı

Task Distribution

Takım Üyesi	Ana Sorumluluklar
İbrahim K.	Veri temizleme, veri kalitesi kontrolü, exploratory data analysis ve temel görselleştirmeler
Abdulkadir T.	Churn prediction modellerinin geliştirilmesi, Logistic Regression baseline, Random Forest/XGBoost karşılaştırması ve model metrikleri
Özlem Ç.	Risk segmentasyonu, pazarlama aksiyonlarının modellenmesi, simülasyon ortamı ve Thompson Sampling implementasyonu
Tuğra C.	Generative AI entegrasyonu, prompt tasarımı, kişiselleştirilmiş pazarlama mesajları ve Streamlit demo
Tüm Ekip	Model ve pazarlama sonuçlarının değerlendirilmesi, final testleri, dokümantasyon ve sunum hazırlığı

Görevler ana sorumlulukları göstermektedir. Birbiriyle bağlantılı aşamalarda ekip üyeleri birlikte çalışacak ve özellikle final değerlendirmesi ortak olarak gerçekleştirilecektir.

2.3 Milestones and Deliverables

Proje ilerlemesini takip etmek için aşağıdaki temel kilometre taşları belirlenmiştir.

Milestone	Beklenen Çıktı / Kanıt
M1 – Data Ready	Temizlenmiş veri seti, eksik değer analizi, sınıf dağılımı ve EDA grafikleri
M2 – Baseline Established	Logistic Regression modeli ve başlangıç ROC-AUC, Recall, F1 ve Lift sonuçları
M3 – Final Churn Model	Random Forest ve XGBoost karşılaştırması sonrası seçilen churn modeli
M4 – Risk Segmentation	Her müşteri için churn probability ve Segment 1–5 ataması
M5 – Simulation Ready	Segment–aksiyon kombinasyonlarına göre sonuç üreten çalışan simülasyon fonksiyonları
M6 – Adaptive Action Selection	Thompson Sampling ile aksiyon seçimi ve zaman içerisindeki reward sonuçları
M7 – AI Content Generation	Farklı müşteri profilleri için seçilen aksiyona uygun Generative AI mesaj örnekleri
M8 – Prototype	Müşteri riskini, seçilen aksiyonu ve oluşturulan mesajı gösteren Streamlit demo
M9 – Final Evaluation	Model metrikleri, segment karşılaştırmaları, average/cumulative reward ve aksiyon dağılımı
M10 – Final Submission	Çalışan kod, GitHub repository, final rapor ve sunum

2.4 Challenges and Mitigation Strategies

Risk	Olası Problem	Mitigation / Fallback
Class Imbalance	Model çoğunluk sınıfını tercih edebilir ve churn müşterilerini kaçırabilir.	Accuracy dışında Recall, F1, ROC-AUC ve Lift kullanılacak; gerekli olursa class weight uygulanacaktır.
Missing Data	Eksik değerler model sonuçlarını etkileyebilir.	Eksiklik oranları incelenecek ve değişken tipine uygun imputation uygulanacaktır.
Overfitting	Model eğitim verisinde iyi, test verisinde düşük performans gösterebilir.	Train/test ayrımı ve cross-validation kullanılacak; model karmaşıklığı kontrol edilecektir.
Yanlış Risk Sıralaması	Churn modeli yanlış müşterileri yüksek risk grubuna koyabilir.	Decile Lift ve segment bazlı churn oranları ayrıca kontrol edilecektir.
Campaign Response Verisi Yok	Gerçek pazarlama aksiyonlarının etkisi doğrudan ölçülemez.	Aksiyon etkisi yalnızca simülasyon olarak gösterilecek ve causal sonuç iddiasında bulunulmayacaktır.
Simulation Bias	Tanımlanan etki aralıkları sonucu önceden yönlendirebilir.	Birden fazla simülasyon senaryosu denenerek sonuçların varsayımlara duyarlılığı incelenecektir.
Bandit Performansı	Thompson Sampling beklenen aksiyonları öğrenmeyebilir.	Rastgele veya sabit aksiyon seçimi baseline olarak tutulacaktır.
LLM Hallucination	Model olmayan kampanya, ürün veya indirim bilgisi üretebilir.	Prompt guardrail kullanılacak; yalnızca verilen aksiyon bilgileriyle mesaj üretmesine izin verilecektir.
API / Cost Limitation	LLM servisi kullanılamayabilir veya demo sırasında bağlantı problemi yaşanabilir.	Önceden üretilmiş örnek mesajlar ve basit template tabanlı mesaj sistemi fallback olarak tutulacaktır.
Streamlit Integration	Arayüz entegrasyonu planlanandan fazla zaman alabilir.	Ana çıktı notebook ve grafikler olacaktır; Streamlit temel sistem tamamlandıktan sonra uygulanacaktır.

2.5 Ethical and Responsible AI Considerations

Bu proje müşteri davranışlarını pazarlama amacıyla değerlendirdiği için yalnızca teknik performans değil, sistemin sorumlu biçimde kullanılması da önemlidir.

Privacy and Consent

Kullanılan Kaggle veri seti eğitim ve araştırma amacıyla kullanılan anonim bir veri setidir. Ancak gerçek bir e-ticaret uygulamasında müşteri davranışlarının pazarlama amacıyla kullanılması KVKK ve ilgili gizlilik gerekliliklerine uygun olmalıdır.

Sistem için gerekli olmayan kişisel verilerin kullanılmaması ve veri minimizasyonu uygulanması gerekir.

Fairness and Bias

Churn modeli geçmiş veride bulunan davranış kalıplarını öğrenmektedir. Bu nedenle veride bulunan olası bias model çıktılarına da yansiyabilir.

Modelin yalnızca toplam performansı değil, mümkün olduğu ölçüde farklı müşteri gruplarındaki performansı da incelenmelidir. Hassas müşteri özellikleri pazarlama kararlarının oluşturulmasında kullanılmamalıdır.

Transparency and Explainability

Churn skorları kesin müşteri davranışı olarak değil, olasılık tahmini olarak sunulacaktır.

Gerçek kullanımda pazarlama ekibi müşterinin hangi risk segmentinde olduğunu ve hangi temel faktörlerin model kararını etkilediğini inceleyebilmelidir.

Manipulation Risk

Kişiselleştirilmiş mesajların amacı müşteriyi yanıltmak veya psikolojik olarak baskı altında bırakmak değildir.

Generative AI'nin müşterinin hassas özelliklerini kullanarak korku, aciliyet veya manipülatif söylemler üretmesine izin verilmemelidir.

Brand Safety and Hallucination

LLM kampanya koşullarını kendisi belirlemeyecektir.

İndirim oranı, kampanya süresi, ürün veya diğer ticari bilgiler sistem tarafından önceden belirlenmiş girdiler olacaktır. Model yalnızca bu bilgilerin iletişim biçimini kişiselleştirecektir.

Üretilen içerikler gerçek müşterilere otomatik gönderilmeden önce tanımlanmış kurallardan ve gerektiğinde insan kontrolünden geçmelidir.

Human Oversight

Önerilen sistem pazarlama çalışanının yerine tamamen otonom karar veren bir sistem olarak tasarlanmaktadır.

Gerçek bir uygulamada pazarlama ekibi:

- hangi aksiyonların kullanılabileceğini,
- kampanya bütçesini,
- indirim sınırlarını,
- marka iletişim kurallarını,

- gönderim kanallarını

belirlemeye devam edecektir.

AI sistemi bu karar sürecine analiz ve öneri sağlayan bir araç olarak kullanılacaktır.

2.6 References

Kaynaklar

- [1] Verma, A. *Ecommerce Customer Churn Analysis and Prediction*. Kaggle Dataset. <https://www.kaggle.com/datasets/ankitverma2010/ecommerce-customer-churn-analysis-and-prediction>
- [2] Devriendt, F., Berrevoets, J., & Verbeke, W. (2021). Why You Should Stop Predicting Customer Churn and Start Using Uplift Models. *Information Sciences*, 548, 497–515.
- [3] Agrawal, S., & Goyal, N. (2013). Thompson Sampling for Contextual Bandits with Linear Payoffs. *Proceedings of the 30th International Conference on Machine Learning*, 28, 127–135.
- [4] Sawant, N., Namballa, C. B., Sadagopan, N., & Nassif, H. (2018). Contextual Multi-Armed Bandits for Causal Marketing.
- [5] Chen, Y., Vankov, E., Baltrunas, L., Donovan, P., Mehta, A., & Schroeder, B. (2023). Contextual Multi-Armed Bandit for Email Layout Recommendation. *Proceedings of the ACM Conference on Recommender Systems*.

AI Kullanımı Beyanı: Bu dokümanın taslak oluşturma, literatürün düzenlenmesi ve dil iyileştirme aşamalarında üretken yapay zekâ araçlarından destek alınmıştır. Projenin veri seti, yöntem seçimi, uygulama kapsamı ve nihai kararları ekip tarafından değerlendirilmiştir.